Лекция 5. Анализ текстовых данных

Технологии и инструментарий анализа больших данных

Курс ТИАБД



Раздел

Место текстовой аналитики в курсе



Основная идея

Главная идея

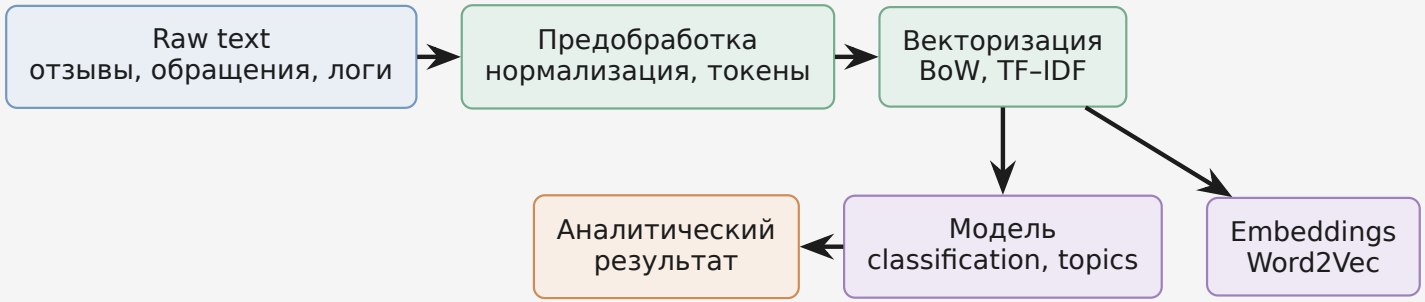
Текст для человека является смысловым сообщением, но для алгоритма машинного обучения изначально является последовательностью символов. Поэтому необходимо построить отображение

$$\text{сырой текст} \to \text{числовое представление} \to \text{модель}.$$

- В табличных данных объект часто уже имеет признаки: дата, сумма, категория, регион.
- В тексте признаки нужно извлечь из неструктурированного языкового материала.
- После векторизации текста снова становятся применимы классификация, кластеризация, поиск сходства и BI-агрегации.



Сквозная логика лекции

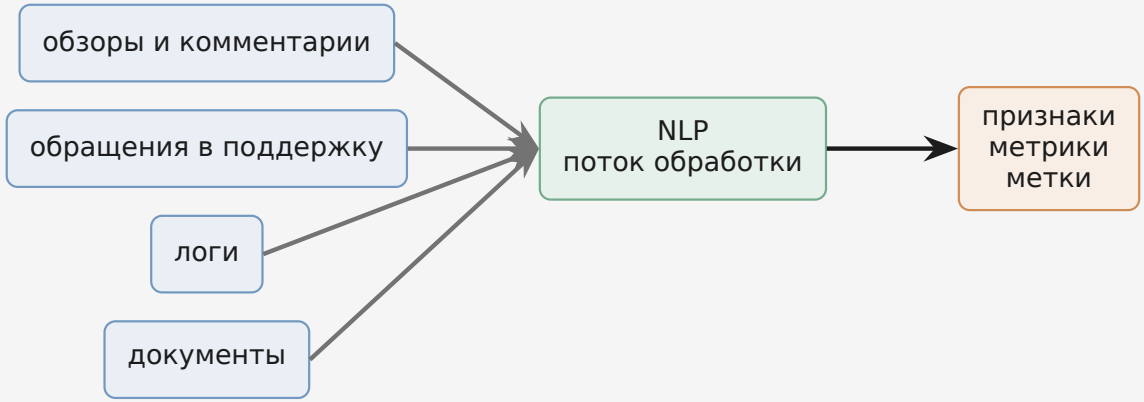


Содержательная траектория

Сначала мы построим классическую статистическую модель текста, затем покажем её ограничения и подготовим переход к контекстным представлениям и Transformer.

Текст как разновидность Big Data

- **Variety**: текст не укладывается в фиксированную реляционную схему.
- **Volume**: корпусы отзывов, логов и документов могут содержать миллионы записей.



- **Veracity**: тексты содержат шум, опечатки, сарказм, разные языки и технические артефакты.
- **Value**: из текста можно извлечь темы, тональность, намерения, проблемы качества.



Почему текст нельзя сразу подать в ML-модель

Классический алгоритм машинного обучения ожидает вектор признаков

$$\boldsymbol{x} = (x_1, x_2, \ldots, x_p) \in \mathbb{R}^p.$$

Текстовая строка изначально не является таким вектором.

Человек видит смысл

`Товар пришёл быстро, качество отличное`

Алгоритм требует числа

$$(0.12,\ 0,\ 0.73, \ldots,\ 0.05)$$

Задача NLP-представления

Построить функцию признакового отображения

$$\phi(d) = \boldsymbol{x}_d,$$

которая переводит документ d в числовой вектор и сохраняет информацию, значимую для аналитической задачи.



Раздел

Базовые понятия: корпус, документ, токен, словарь



Документ и корпус

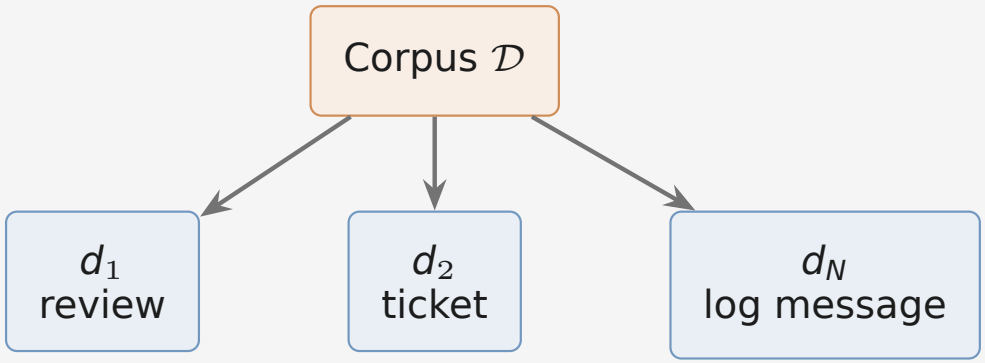
Документ

Документ — отдельный текстовый объект, рассматриваемый как единица анализа: отзыв, обращение, письмо, статья, описание товара или строка журнала событий.

Корпус

Корпус — коллекция документов:

$$\mathcal{D} = \{d_1, d_2, \ldots, d_N\}.$$



Токен и словарь

После токенизации документ можно представить последовательностью

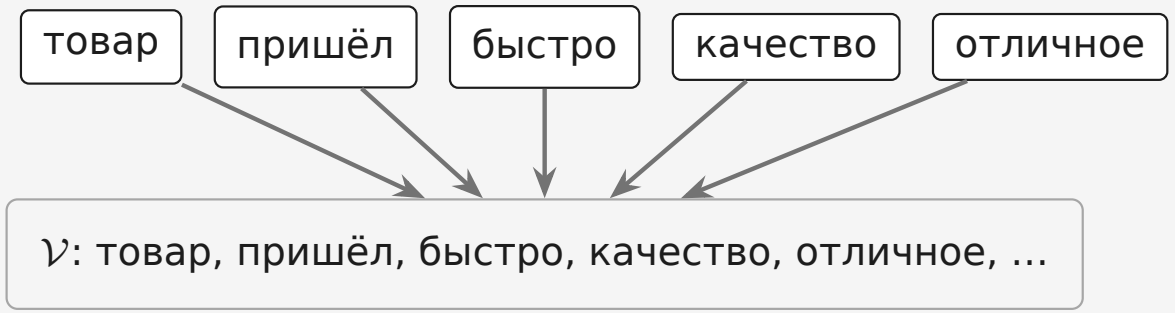
$$d_i = (w_1, w_2, \ldots, w_m),$$

где w_j — токен.

Словарь

Словарь — множество токенов, которые модель учитывает как признаки:

$$\mathcal{V} = \{t_1, t_2, \ldots, t_{|\mathcal{V}|}\}.$$



Матрица «документ–термин»

Если каждому термину словаря поставить в соответствие столбец, корпус превращается в матрицу

$$X = [x_{ij}] \in \mathbb{R}^{N \times |\mathcal{V}|}.$$

	t_1	t_2	t_3	$\ldots$	$t_{\lvert\mathcal{V}\rvert}$
d_1	1	0	2	$\ldots$	0
d_2	0	1	0	$\ldots$	3
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$
d_N	0	0	1	$\ldots$	0

строка — документ, столбец — термин, значение — частота или вес

Дальше разные методы будут отличаться тем, как именно вычисляется x_{ij}.

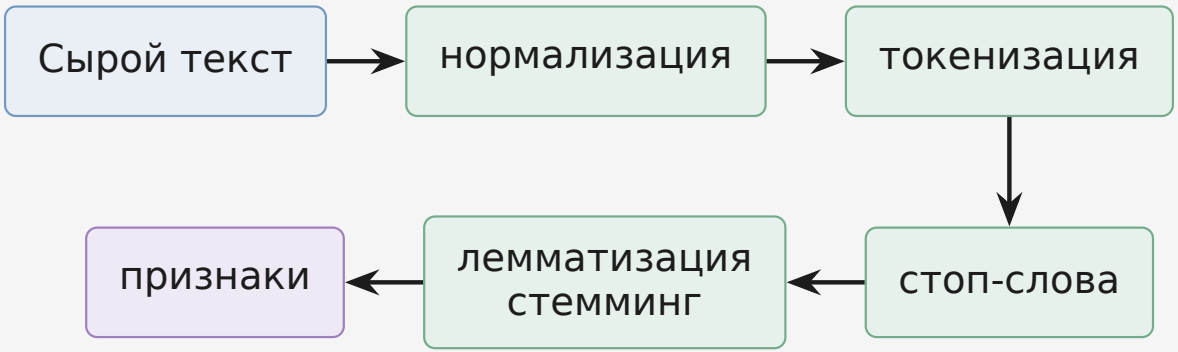


Раздел

Предобработка текста



Классический поток предобработки



Методологический принцип

Предобработка не должна быть механическим «очищением». Каждая операция должна отвечать на вопрос: какая информация является шумом, а какая — сигналом для данной задачи?



Нормализация текста

Нормализация приводит строки к более единообразному виду.

Исходный фрагмент	После нормализации

`ДОСТАВКА  отличная!!!`
`Подробнее:`
`https://site.ru/item/123`
	`доставка отличная ! ! !`
	`подробнее <URL>`

Типичные операции:

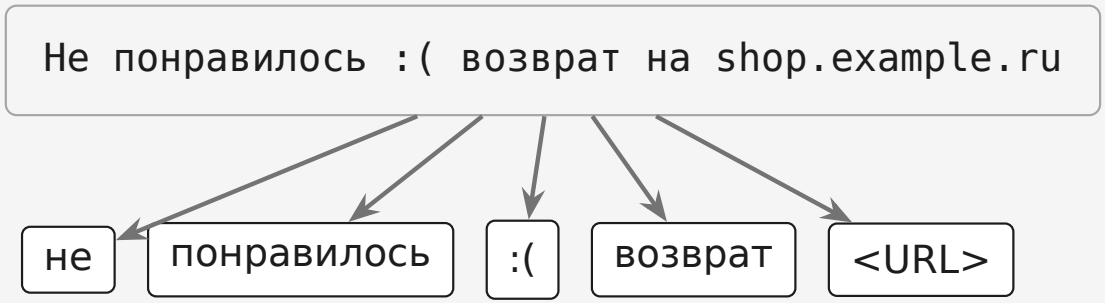
- приведение регистра;
- нормализация пробелов и кодировочных артефактов;
- обработка URL, e-mail, телефонов, номеров заказов;
- унификация чисел, денежных сумм, технических идентификаторов.



Токенизация как разбиение текста

Определение

Токенизация — разбиение текста на элементарные единицы анализа: слова, части слов, символы, специальные маркеры или их комбинации.



Пунктуация, эмоджи, URL, числа и хештеги могут быть либо шумом, либо полезным признаком.



Стоп-слова

Определение

Стоп-слова — часто встречающиеся слова, которые в конкретной задаче могут иметь низкую различительную способность.

Тематическая классификация

Слова вроде «и», «в», «на» часто мало помогают различать темы документов.

Сентимент анализ

Частица «не» может полностью менять тональность: хороший $\neq$ не хороший

Стоп-лист должен зависеть от предметной области и целевой задачи, а не применяться автоматически.



Стемминг и лемматизация

Стемминг

Эвристическое сокращение слова до основы. Результат не обязан быть нормативной словарной формой.

кошками $\rightarrow$ кошк

Лемматизация

Приведение слова к словарной форме с учётом морфологии.

доставили $\rightarrow$ доставить

Зачем это нужно

Русская морфология создаёт много словоформ одного понятия. Сведение форм уменьшает словарь и повышает статистическую устойчивость признаков.



Раздел

Мешок слов и N-граммы



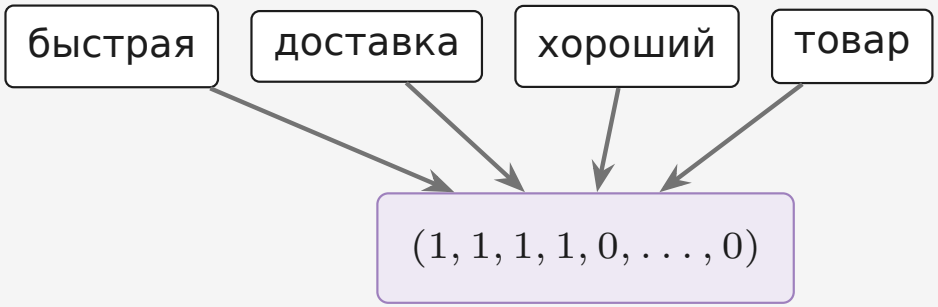
Мешок слов как базовая модель текста

Определение

Bag of Words представляет документ вектором частот терминов без учёта порядка слов:

$$\boldsymbol{x}_d = (c_1, c_2, \ldots, c_{|\mathcal{V}|}),$$

где c_j — число вхождений термина t_j в документ d.





Пример BoW-матрицы

Документ	быстрая	доставка	хороший	товар	хорошая	цена	плохая	поврежден
d_1	1	1	1	1	0	0	0	0
d_2	0	0	1	1	1	1	0	0
d_3	0	1	0	1	0	0	1	1

Достоинство

Простота, интерпретируемость, совместимость с линейными моделями.

Недостаток

Порядок слов и синтаксические связи исчезают.



Разреженность текстовых признаков

Если $|\mathcal{V}| = 100\,000$, а короткий отзыв содержит 30 различных токенов, доля ненулевых компонент равна

$$\rho = \frac{nnz(\boldsymbol{x}_d)}{|\mathcal{V}|} = \frac{30}{100000} = 0.0003 = 0.03\%.$$



плотное хранение нерационально, ибо почти все значения равны нулю

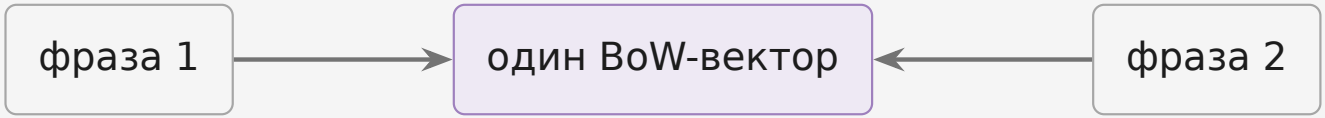
Инженерный вывод

Для текстов важны разреженные вектора. Они экономят память, дисковое хранение и сетевой обмен в распределённой обработке.

Проблема порядка слов

BoW не различает документы, если они содержат одинаковые токены с одинаковыми частотами.

Фраза 1	Фраза 2
клиент любит товар	товар любит клиент



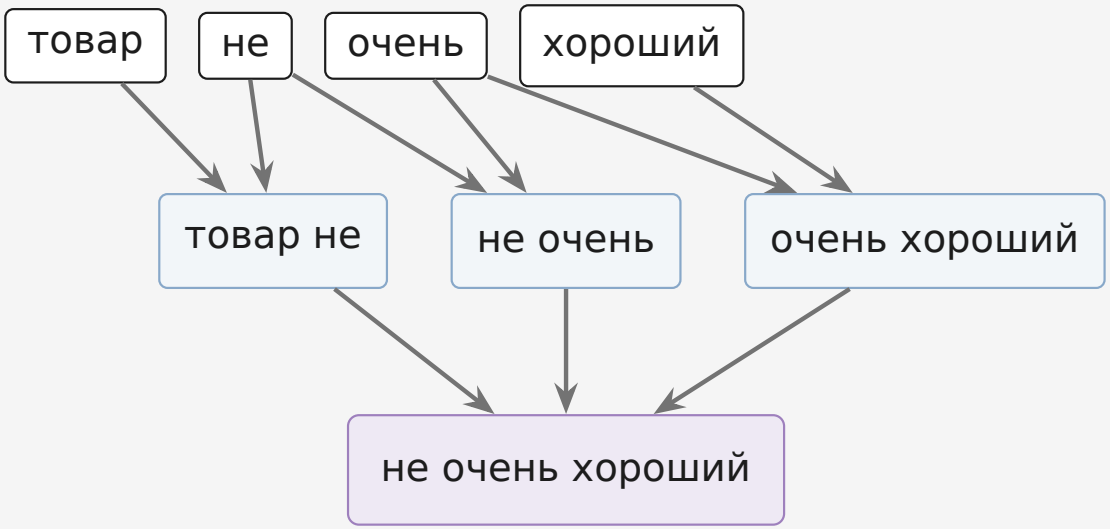
Это допустимо для некоторых тематических задач, но плохо для синтаксически чувствительных смыслов.



N-граммы, сохраняющие порядок

Определение

***N*-грамма** — последовательность из *n* соседних токенов.



Биграммы и триграммы частично восстанавливают локальный контекст, но увеличивают размерность словаря.



Цена N-грамм

Если словарь униграмм имеет размер $|\mathcal{V}|$, теоретическое число возможных последовательностей длины n растёт как

$$O(|\mathcal{V}|^n).$$

Плюс

Появляются признаки вида

не хороший, очень плохой.

Модель лучше видит короткие устойчивые выражения.

Минус

Растут словарь, разреженность, память, риск переобучения и стоимость обучения.



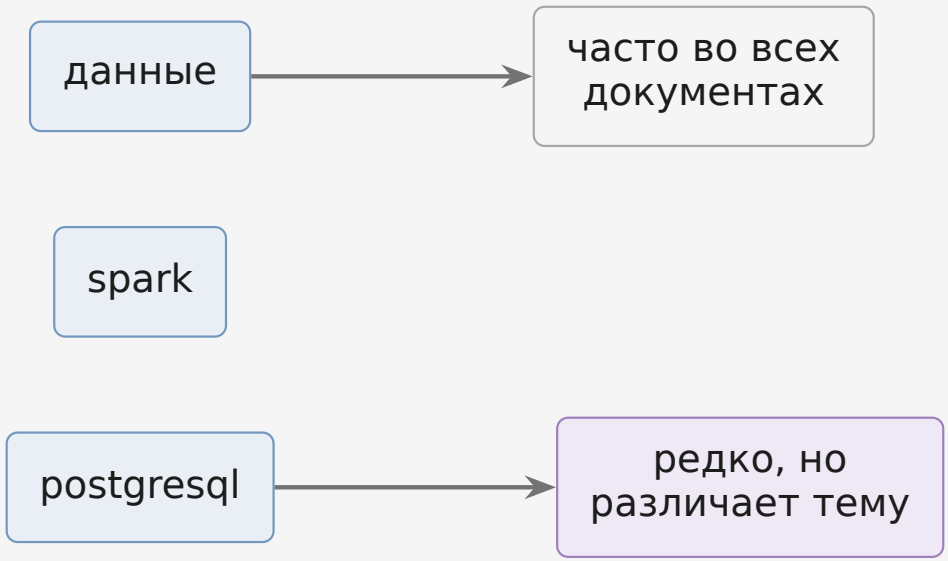
Раздел

TF–IDF и сходство документов



Почему простой частоты недостаточно

В BoW часто встречающиеся слова получают большой вес, даже если они есть почти во всех документах.



Идея TF–IDF

Термин должен иметь большой вес, если он заметен в данном документе, но не является повсеместно распространённым во всём корпусе.

TF локальная частота

Term Frequency

$$TF(t,d) = \frac{n_{t,d}}{\sum_k n_{k,d}},$$

где $n_{t,d}$ — число появлений термина t в документе d.

- *TF* нормирует частоту на длину документа.
- Сравнимыми становятся короткие и длинные тексты.
- *TF* отвечает на вопрос: насколько термин заметен внутри документа?

Пример

Если документ содержит 100 токенов, а термин встретился 5 раз:

$$TF = \frac{5}{100} = 0.05.$$



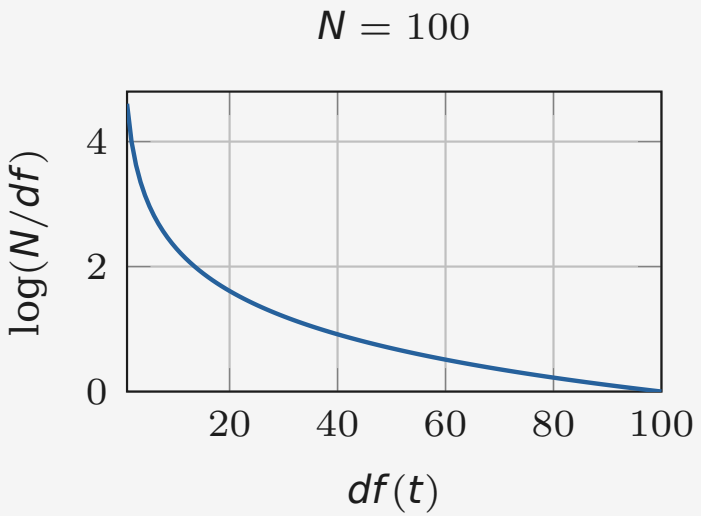
IDF глобальная редкость

Inverse Document Frequency

$$IDF(t) = \log \frac{N}{df(t)},$$

где $df(t)$ — число документов корпуса, содержащих термин t.

- Если термин есть во всех документах, $df(t) = N$.
- Тогда $IDF(t) = \log 1 = 0$.
- Редкие термины получают больший вес.



TF–IDF как итоговый вес

Формула

$$TFIDF(t, d) = TF(t, d) \cdot IDF(t).$$



Интерпретация

Высокий TF–IDF получают термины, характерные для данного документа и сравнительно редкие в корпусе.

Численный пример TF–IDF

Корпус из четырёх документов:

d_1 : spark быстро обрабатывает данные
d_2 : spark анализирует большие данные
d_3 : postgresql хранит данные
d_4 : данные требуют качества

Термин «данные»

$$N = 4, \quad df = 4,$$

$$IDF = \log \frac{4}{4} = 0.$$

Термин «postgresql»

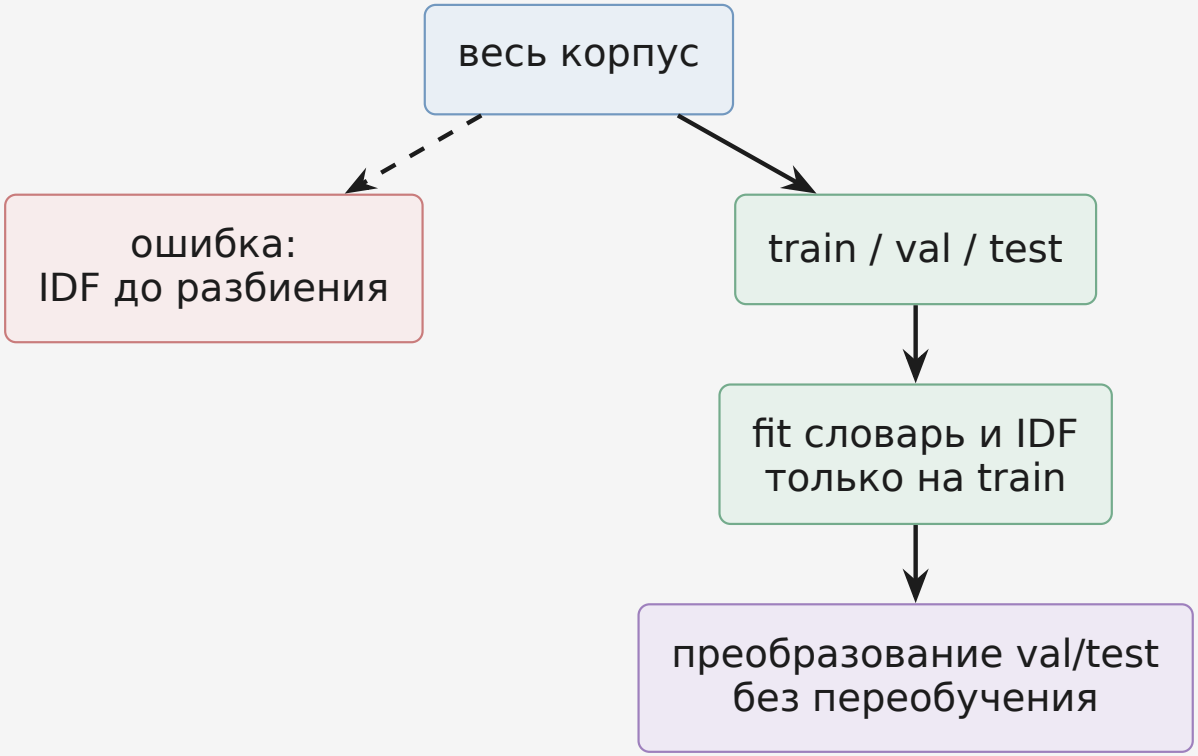
$$df = 1, \quad IDF = \log 4 \approx 1.386.$$

Если $TF = 1/3$, то

$$TFIDF \approx 0.462.$$



Утечка данных при вычислении IDF



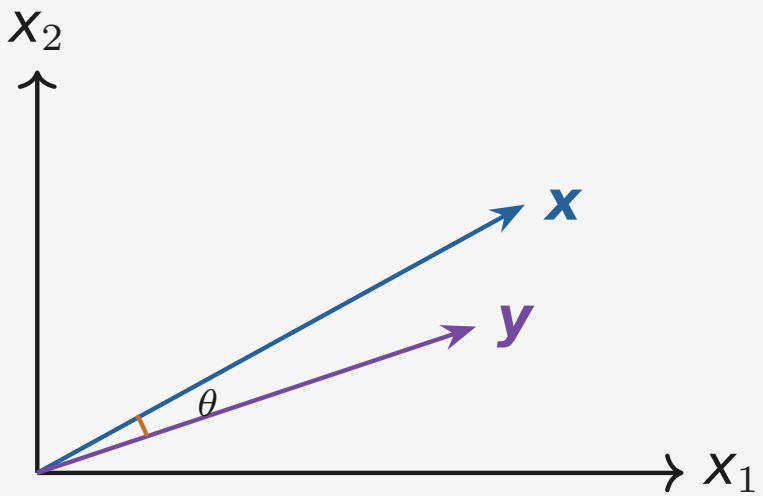
Правило

Все параметры векторизатора, включая словарь и IDF, являются частью обучаемого потока обработки и должны оцениваться только по обучающей выборке.

Косинусное сходство

Когда документы представлены векторами, их близость удобно измерять через угол:

$$\cos(\boldsymbol{x}, \boldsymbol{y}) = \frac{\boldsymbol{x} \cdot \boldsymbol{y}}{\|\boldsymbol{x}\| \, \|\boldsymbol{y}\|}.$$



Косинус используется и для TF–IDF-векторов, и позднее для векторных представлений токенов.



Раздел

Сентимент анализ и классификация текстов



Анализ тональности как классификация

Постановка

По тексту отзыва нужно предсказать оценочную метку: позитивная, негативная или нейтральная.

Для таблицы `ecommerce.order_reviews` можно задать бинарную целевую переменную:

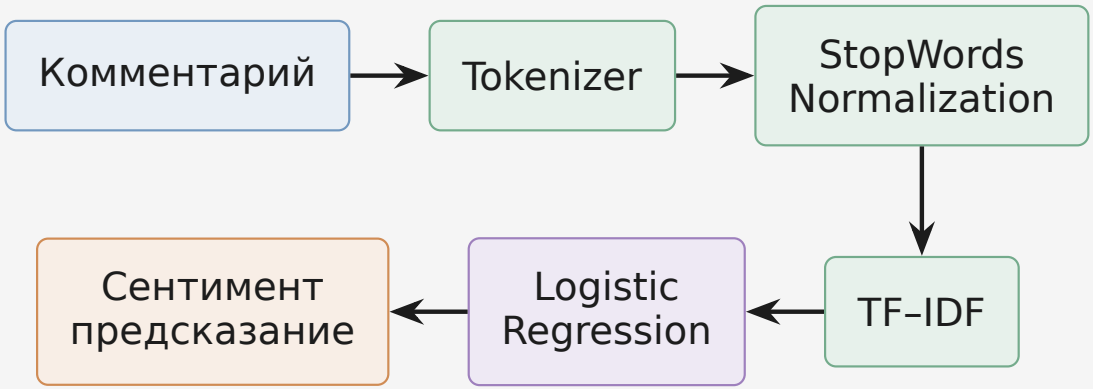
$$y = \begin{cases} \mathit{negative}, & \mathit{score} \le 2, \\ \mathit{positive}, & \mathit{score} \ge 4. \end{cases}$$

Замечание о классе 3

Оценка $\mathit{score} = 3$ в бинарной постановке либо исключается, либо задача меняется на трёхклассовую: negative / neutral / positive.



Пайплайн для сентимент анализа



Модель

$$P(y = 1 \mid \boldsymbol{x}) = \sigma(\boldsymbol{w}^T \boldsymbol{x} + b), \qquad \sigma(z) = \frac{1}{1 + e^{-z}}.$$



Интерпретируемость линейной модели

В TF–IDF + Logistic Regression каждому признаку соответствует коэффициент.

Положительные веса	Отрицательные веса
отличный	плохой
быстро	сломанный
доволен	возврат
рекомендую	ужасно

Коэффициент показывает статистическую связь в данном корпусе, а не универсальное значение слова.



Метрики качества текстовой классификации

Precision

$$Precision = \frac{TP}{TP + FP}$$

Сколько найденных негативных отзывов действительно негативны?

Recall

$$Recall = \frac{TP}{TP + FN}$$

Сколько всех негативных отзывов модель нашла?

F_1-мера

$$F_1 = 2\frac{Precision \cdot Recall}{Precision + Recall}.$$

Компромисс между точностью и полнотой.

Почему не только accuracy

При дисбалансе классов высокая accuracy может скрывать плохое обнаружение редкого, но важного класса.



Типичные ошибки сентимент-модели

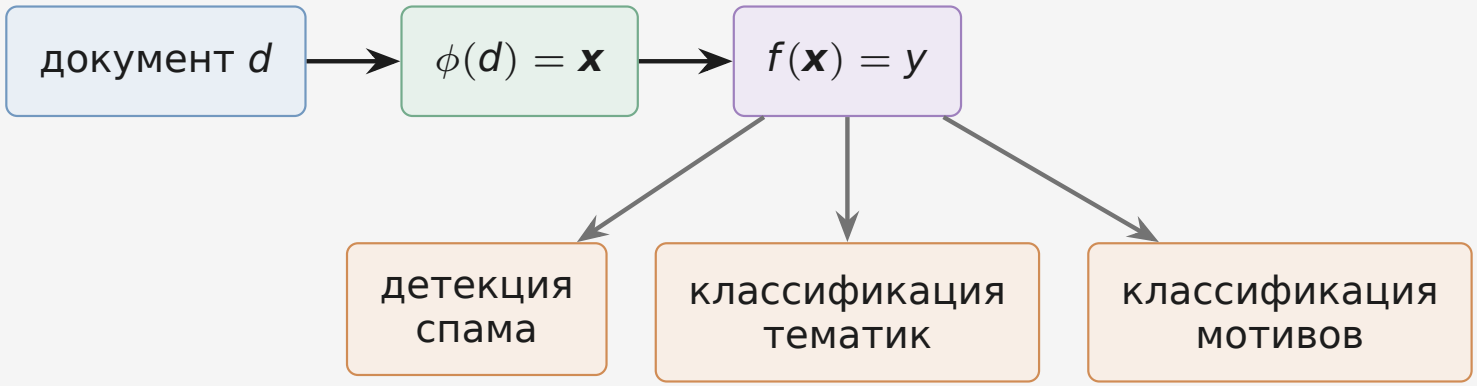
Пример	Почему сложно
`Товар не хороший`	отрицание может быть удалено или не связано с оценочным словом
`Просто идеальная доставка: коробка пришла через месяц`	сарказм и конфликт локального слова с общим смыслом
`Качество хорошее, доставка ужасная`	несколько аспектов внутри одного документа
`норм`	короткий текст, слабый контекст, разговорная лексика

Вывод

Анализ ошибок вручную необходим, так как метрика говорит «сколько», но не объясняет «почему».



Другие задачи классификации текстов



- **мультикласс**: ровно один класс из K;
- **мультиметка**: документ может иметь несколько меток одновременно.



Раздел

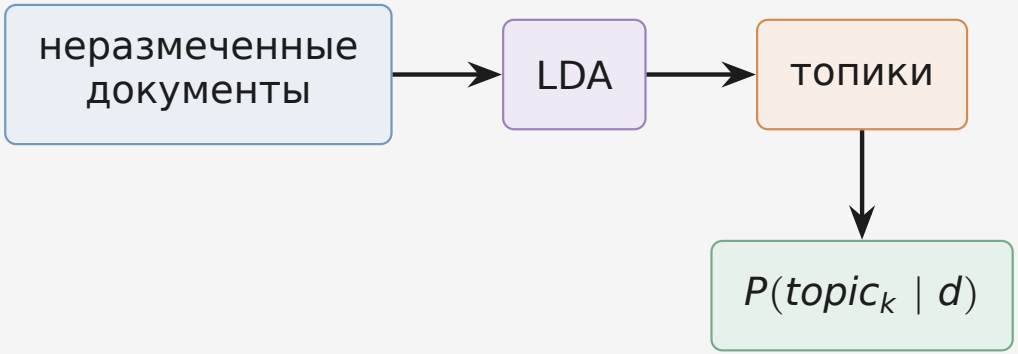
Тематическое моделирование



Что такое математическое моделирование

Идея

Тематическое моделирование ищет скрытую тематическую структуру корпуса без заранее размеченных классов.



LDA — инструмент разведочного анализа, а не магическое извлечение «истинных тем».



LDA, где документ как смесь тем

Вместо жёсткого присвоения одной темы документу LDA использует распределение

$$\boldsymbol{\theta}_d = (\theta_{d1}, \theta_{d2}, \ldots, \theta_{dK}), \qquad \sum_{k=1}^{K} \theta_{dk} = 1.$$

Тема документа	Доля
качество товара	0.55
доставка	0.35
оплата	0.10

Интерпретация

Название темы задаёт аналитик после просмотра слов с наибольшими вероятностями в данной теме.



LDA, где тема как распределение слов



Раздел

Векторное представление слов



Проблема one-hot и BoW

В BoW каждое слово — отдельная координата. Слова «автомобиль» и «машина» оказываются независимыми признаками.

$$\boldsymbol{v}_{\text{автомобиль}} = (0, 0, 1, 0, \ldots, 0), \qquad \boldsymbol{v}_{\text{машина}} = (0, 0, 0, 0, \ldots, 1).$$

Их скалярное произведение равно нулю:

$$\boldsymbol{v}_{\text{автомобиль}} \cdot \boldsymbol{v}_{\text{машина}} = 0.$$

Проблема

Семантическая близость слов не кодируется в самой геометрии пространства признаков.

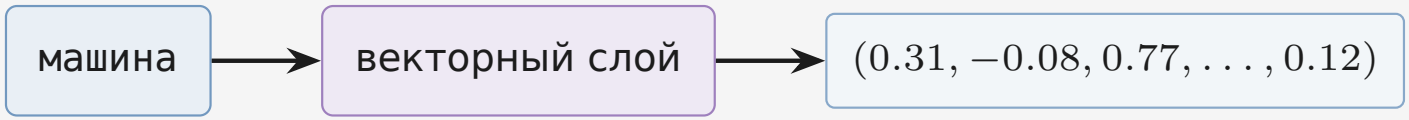


Векторное представление как плотный вектор слова

Определение

Embedding — отображение дискретного объекта в плотный вещественный вектор:

$$word \to \boldsymbol{v}_w \in \mathbb{R}^d, \qquad d \ll |\mathcal{V}|.$$



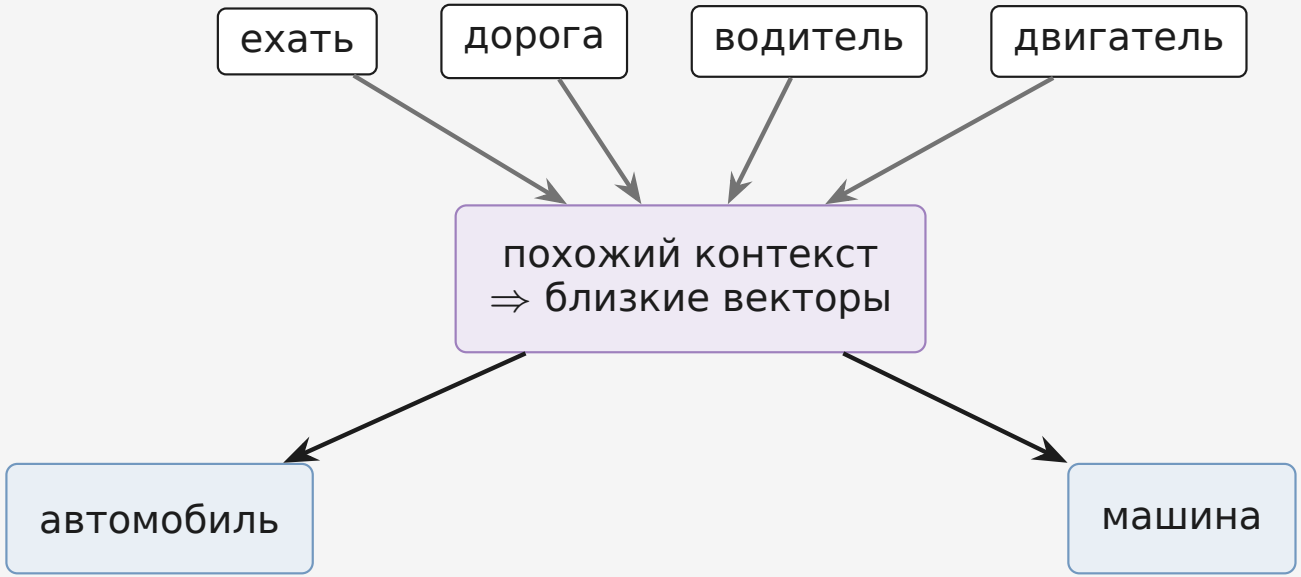
Отдельная координата обычно не имеет простой интерпретации; смысл задаётся геометрией всего пространства.



Распределительная гипотеза

Интуиция

Слова, встречающиеся в похожих контекстах, вероятно, имеют близкие функции и значения.





Word2Vec. Две постановки

CBOW

Предсказать центральное слово по контексту:

$$context \to center\ word.$$

`быстрая _ товара`

Skip-gram

Предсказать контекст по центральному слову:

$$center\ word \to context.$$

`доставка` $\to$ `быстрая, товара`

Смысл обучения

Модель вынуждена разместить слова в пространстве так, чтобы слова с похожими контекстами имели похожие векторы.



Векторное пространство слов



Реальные embeddings имеют десятки или сотни измерений; на слайде показана условная 2D-проекция.

Ограничение статических векторных представлений

В Word2Vec каждому слову соответствует один вектор:

$$w \to \boldsymbol{v}_w.$$

Но значение слова может зависеть от предложения.

Контекст 1

лук лежит на кухне

Контекст 2

спортсмен натянул лук

Переход

Нужен вектор токена, зависящий от всей последовательности:

$$\boldsymbol{h}_i = f(w_1, w_2, \ldots, w_n, i).$$

Именно это приводит к контекстным векторным представлениям и Transformer.



Раздел

Текстовая аналитика в распределённой среде

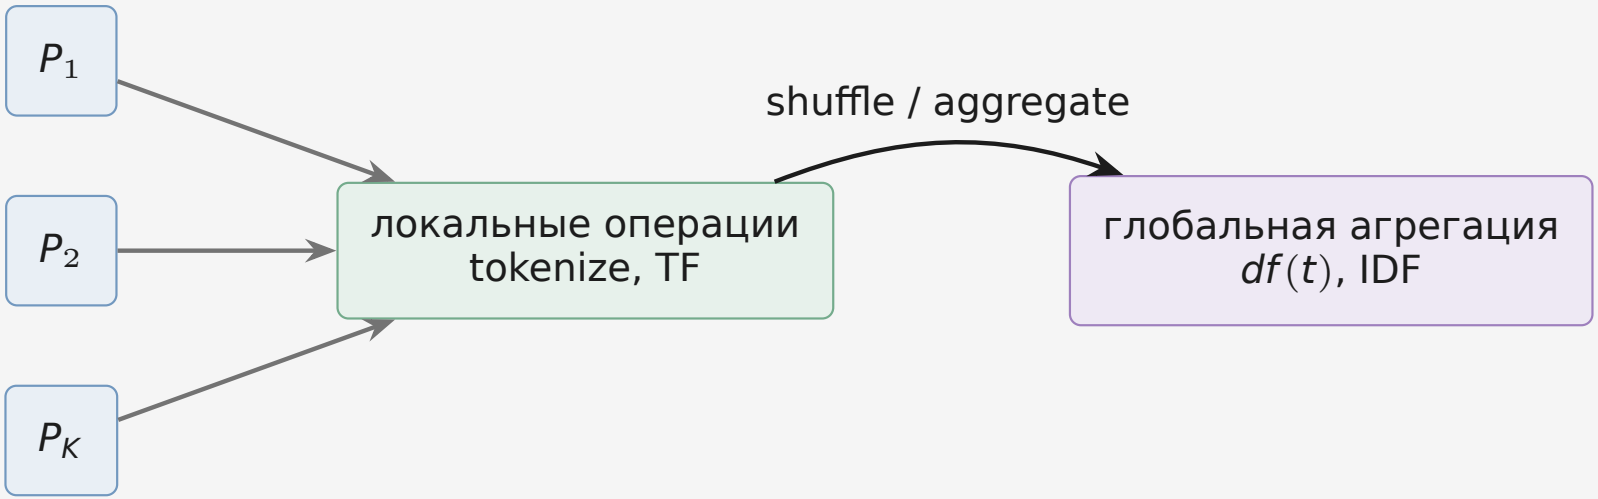


Где здесь Spark

Большие текстовые корпуса требуют распределённой обработки. Пусть

$$\mathcal{D} = P_1 \cup P_2 \cup \ldots \cup P_K,$$

где P_k — партиция.





Локальные и глобальные операции

Локально по документу

$$text_i \to tokens_i$$

$$tokens_i \to TF_i$$

Документы можно обрабатывать независимо.

Глобально по корпусу

$$df(t) = \sum_{i=1}^{N} I(t \in d_i).$$

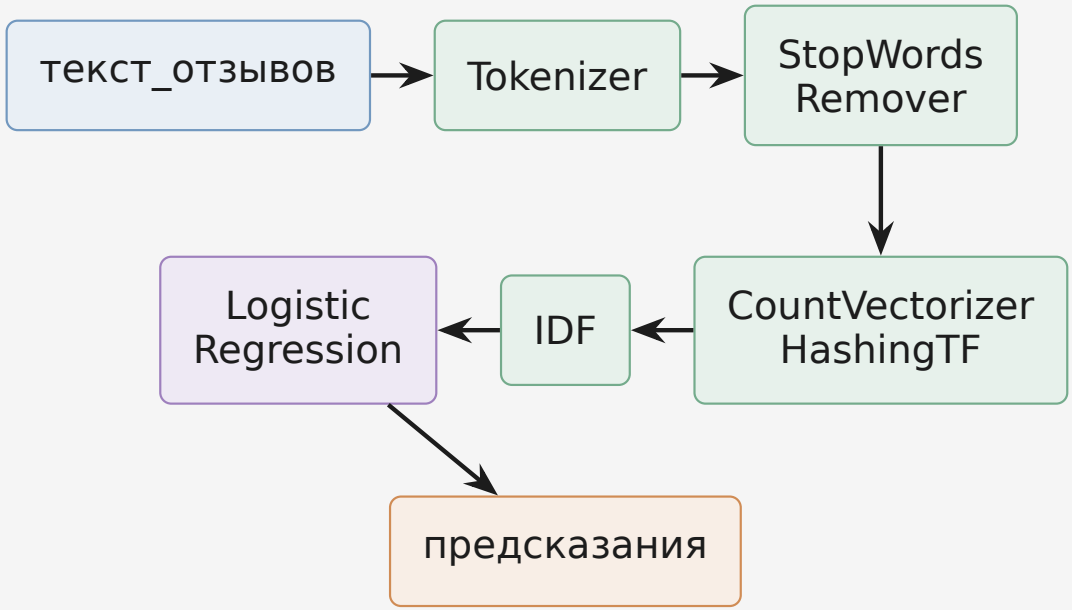
Нужна агрегация статистик по партициям.

Инженерный смысл

Стоимость NLP пайплайна определяется не только формулами, но и количеством проходов по корпусу, размером словаря и сетевыми перераспределениями.



Spark ML pipeline для отзывов



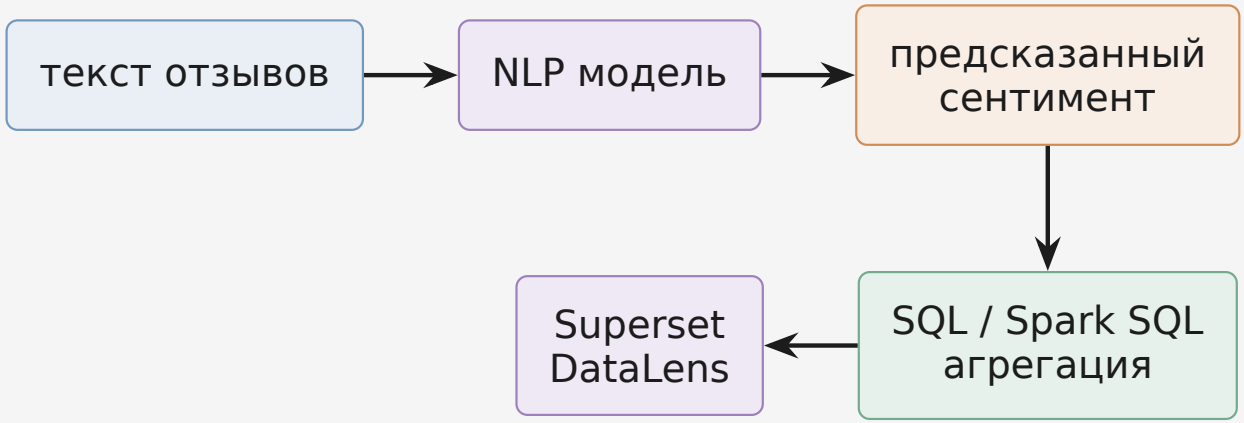
Связь с лекцией 4

Текстовая обработка в Spark ML всё равно следует схеме Transformer $\rightarrow$ Estimator $\rightarrow$ Model.



Из NLP обратно в BI

Результат текстовой модели становится структурированным аналитическим атрибутом.



Архитектурный вывод

NLP не изолирован от общей платформы. Он преобразует неструктурированный текст в признаки, метрики и витрины, доступные для аналитики и визуализации.

Раздел

Ограничения классического NLP и переход к Transformer



Сравнение представлений текста

Метод	Размерность	Порядок слов	Семантическая близость	Основное ограничение
BoW	$\lvert\mathcal{V}\rvert$	нет	нет	теряется структура
TF–IDF	$\lvert\mathcal{V}\rvert$	нет	нет	вес $\neq$ понимание смысла
N-граммы	высокая	локально	ограниченно	взрыв размерности
Word2Vec	$d \ll \lvert\mathcal{V}\rvert$	через контекст обучения	да	один вектор на слово
Contextual embeddings	скрытая размерность	да	да	вычислительно дороже



Что классические методы теряют

- **BoW / TF–IDF** плохо моделируют порядок и синтаксические зависимости.
- **N-граммы** видят только короткий локальный контекст и быстро увеличивают размерность.
- **TF–IDF** измеряет статистическую различимость, но не семантику как таковую.
- **Word2Vec** создаёт плотную семантическую геометрию, но не различает значения слова по конкретному предложению.

Главный переход

Нужно перейти от заранее сконструированных признаков к модели, которая сама строит контекстное представление токена внутри последовательности.



Контрольные вопросы

1. Чем документ, корпус, токен и словарь отличаются друг от друга?
2. Почему BoW-представление одновременно простое и принципиально ограниченное?
3. Как вычисляются $TF(t, d)$, $IDF(t)$ и $TFIDF(t, d)$?
4. Почему IDF нельзя обучать на всём датасете до train/test split?
5. Чем sentiment analysis является задачей классификации?
6. Как LDA представляет документ и тему?
7. Чем embedding отличается от one-hot/BoW-представления?
8. Почему статический Word2Vec недостаточен для многозначных слов?
9. Какие этапы NLP pipeline требуют распределённой агрегации?
10. Что мотивирует переход к Attention и Transformer?



Ключевые термины

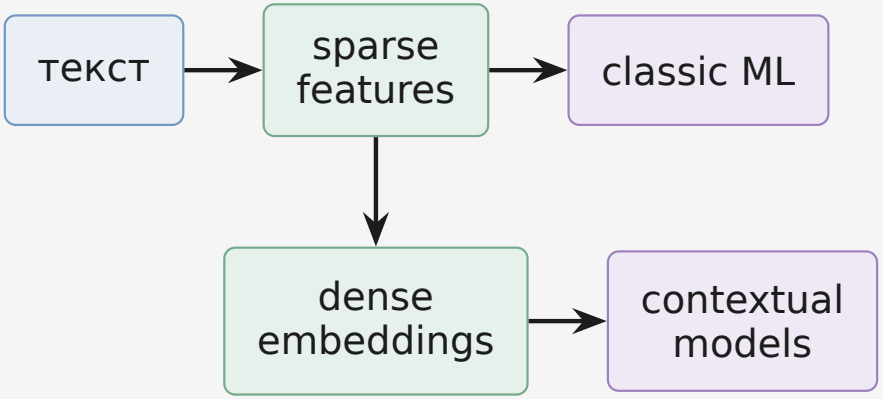
- text analytics
- NLP
- document
- corpus
- token
- vocabulary
- normalization
- tokenization
- stop words
- stemming
- lemmatization
- Bag of Words
- sparse vector
- *N*-gram
- TF
- DF
- IDF
- TF–IDF
- cosine similarity
- sentiment analysis
- topic modeling
- LDA
- embedding
- Word2Vec
- contextual embedding



Финальный вывод

Итог

Классическая аналитика текстов строится вокруг преобразования текста в признаки. Она остаётся важной благодаря простоте, скорости и интерпретируемости, но её ограничения напрямую показывают, зачем нужны контекстные нейронные представления.





Спасибо за внимание

